웹 크롤러는 링크를 따라 페이지를 수집한다

예시: 대학 공지 목록에서 시작해 공지 본문을 모으는 수집기를 만든다면

1. 목록 페이지 요청

a.example/notices
HTML과 링크를 받음

→

2. 공지 링크 발견

/notices/101
/notices/102

→

3. 본문 수집과 저장

각 링크의 페이지를 요청
찾은 새 링크도 수집 후보로 추가

크롤러가 관리할 질문

다음에는 무엇을 받을까?　　같은 사이트에 너무 자주 요청하지는 않을까?

이미 모은 내용인가?　　실패한 작업과 바뀐 페이지는 언제 다시 볼까?

검색 엔진은 수집한 페이지를 바탕으로 색인을 만든다. 수집과 검색은 별도 단계다.

수집 작업의 전체 흐름

시작 URL을 큐에 넣고, 페이지에서 발견한 링크를 다시 큐로 보낸다



미수집 URL 큐는 앞으로 할 일, 콘텐츠 저장소는 수집한 본문을 보관한다.

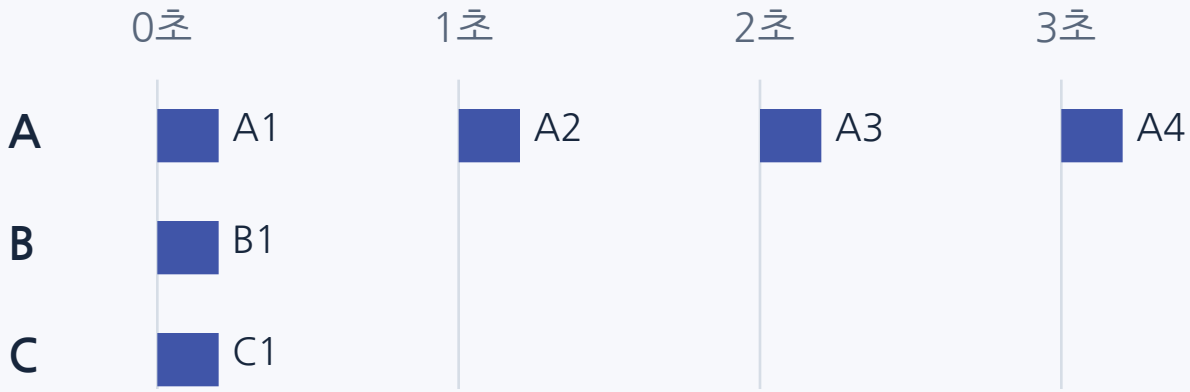
중요한 페이지를 고르면서 요청 간격도 지키기

가정: 호스트별 요청 시작 간격 1초 이상, 응답 시간 0.2초, 작업자 6명

대기 작업 6개

A 사이트	A1, A2, A3, A4
B 사이트	B1
C 사이트	C1

가장 빠른 요청 시작 시점



전면 큐: 중요한 페이지를 먼저 선택

후면 큐: 같은 호스트를 묶고 요청 간격을 지킴

첫 시점에는 A1·B1·C1만 요청한다. 작업자 증설과 대상 사이트의 허용 속도는 별개다.

문제 1. HTML이 같으면 링크 추출도 생략할까?

가정: 두 페이지의 HTML 바이트가 같고, 리다이렉션과 base 태그는 없다

방문한 주소 A

https://a.example/a/index.html

방문한 주소 B

https://a.example/b/index.html

두 HTML의 링크

```
<a href="detail.html">상세 보기</a>
```

A는 처리했다. HTML이 같은 B의 링크 추출도 생략해도 될까?

생략해도 된다고 생각한다면

그렇게 판단한 이유는 무엇인가요?

생략하면 안 된다고 생각한다면

어떤 문제가 생길 수 있을까요?

선택과 근거를 먼저 이야기한 뒤, 함께 확인해 봅시다.

문제 2. 새 페이지라면 계속 수집할 가치가 있을까?

가정: 하루 수집 예산 300페이지. 달력의 다음 날 링크가 먼 미래까지 새 페이지를 만든다

중복 검사도, URL 길이 제한도 통과

매번 새 날짜라 URL이 다름

날짜가 달라 HTML 해시도 다름

경로 깊이와 URL 길이는 거의 같음

/calendar?date=2040-01-01

↓

/calendar?date=2040-01-02

↓

/calendar?date=2040-01-03

URL도 내용도 매번 새로운 달력 페이지가 계속 나온다면,
중복 검사나 URL 길이 제한만으로는 원하는 수집이 어려워 보입니다.

어떤 탐색 알고리즘이나 제한 정책을 적용해야 할까요?